LEGALCLOUD AI

Frameworks de arquitectura RAG

Primero, el mejor de cada categoría · 14 de octubre de 2026

Catálogo de 36 frameworks para la arquitectura RAG de LegalCloud AI. El orden abre con el mejor de cada categoría, elegido para la búsqueda híbrida, las citas con página y versión, y un servicio que Laravel llama desde fuera de la API. Dentro de cada lista, el número 1 es ese mismo framework. La licencia gratuita se instala en tu servidor. El precio bajo es un plan chico, pago por uso o una GPU. Lo caro es licencia empresarial, GPU de NVIDIA o muchas llamadas al modelo al indexar. Si el modelo no es local, sus tokens se pagan en los tres grupos.

1. Los mejores de cada categoría

Este es el orden de arranque: primero el mejor gratis, después el mejor de precio bajo y al final el mejor de los caros.

1 Haystack GRATIS

Encabeza los gratis porque el pipeline ya trae búsqueda léxica, semántica e híbrida, el modo con el que LegalCloud consulta el fondo.
Recupera pasajes, puede reordenarlos y devolver el origen. Laravel lo llama como servicio y guarda página, versión y hash.

https://haystack.deepset.ai/

2 Dify PRECIO BAJO

Encabeza los de precio bajo porque el flujo se publica como API con una cuota mensual baja, o se instala en tu servidor sin licencia.
El flujo de buscar, citar y responder se arma en un panel. Esa API puede atender la búsqueda y los mensajes del asistente.

https://dify.ai/

3 NeMo Retriever CARO

Encabeza los caros porque extrae texto, tablas y figuras del PDF y reordena los pasajes con la pila de NVIDIA.
El costo está en la licencia y en las GPU. Sirve cuando el volumen del fondo y el tiempo de respuesta piden un recuperador empresarial.

https://docs.nvidia.com/nemo/retriever/latest/

2. Gratis

Se instalan en tu servidor. No hay tarifa de licencia. Haystack va primero.

1 Haystack GRATIS

Encabeza los gratis porque el pipeline ya trae búsqueda léxica, semántica e híbrida, el modo con el que LegalCloud consulta el fondo.
Recupera pasajes, puede reordenarlos y devolver el origen. Laravel lo llama como servicio y guarda página, versión y hash.

https://haystack.deepset.ai/

2 LlamaIndex GRATIS

Indexa por páginas y devuelve el trozo con su origen.
Sirve para guardar fragmento, página y versión en la evidencia de la consulta.

https://www.llamaindex.ai/

3 LLMWare GRATIS

Está hecho para contratos y documentos largos, y la respuesta sale con la cita.
Sirve para reglamentos y resoluciones del fondo legal.

https://github.com/llmware-ai/llmware

4 RAGFlow GRATIS

Trocea el PDF con detalle y puede señalar de qué zona salió la cita.
Sirve para reglamentos escaneados, donde importan la página y el párrafo.

https://ragflow.io/

5 LangGraph GRATIS

El turno queda en pasos: buscar, elegir fragmentos, citar y responder.
Sirve cuando la pregunta del consultor no se resuelve con una sola búsqueda.

https://github.com/langchain-ai/langgraph

6 R2R GRATIS

Ofrece API de carga, búsqueda y respuesta.
Sirve para emparejarla con la búsqueda y con los mensajes de la conversación.

https://github.com/SciPhi-AI/R2R

7 LangChain GRATIS

Arma la cadena de buscar y luego responder.
Laravel la llama como servicio para el asistente sobre el expediente.

https://github.com/langchain-ai/langchain

8 LlamaStack GRATIS

Junta recuperación, modelo y evaluación en un solo servicio.
Sirve para dejar el índice y el modelo fuera de la API, como ya está dibujado en el sistema.

https://github.com/meta-llama/llama-stack

9 DSPy GRATIS

Declaras la pregunta, el contexto y la cita, y él ajusta los prompts con ejemplos.
Sirve para afinar el resumen sustentado y comprobar que usa el reglamento citado.

https://github.com/stanfordnlp/dspy

10 LightRAG GRATIS

Arma un grafo liviano de entidades y relaciones.
Sirve cuando una norma remite a otra y quieres seguir ese vínculo con pocas llamadas al modelo.

https://github.com/HKUDS/LightRAG

11 Cognita GRATIS

Separa la ingesta de documentos y la pregunta en un servicio desplegable.
Sirve para colocar el índice semántico fuera de Laravel.

https://github.com/truefoundry/cognita

12 PrivateGPT GRATIS

Las preguntas corren contra archivos locales.
Sirve para un fondo reservado que permanece en la red de la organización.

https://github.com/zylon-ai/private-gpt

13 AnythingLLM GRATIS

Cada expediente puede ser un espacio con sus documentos.
Sirve para ensayar que el consultor solo pregunte sobre lo que tiene asignado.

https://github.com/Mintplex-Labs/anything-llm

14 FastRAG GRATIS

Son pipelines cortos, pensados para responder con menos espera.
Sirve cuando el mismo expediente se consulta muchas veces.

https://github.com/IntelLabs/fastRAG

15 Kotaemon GRATIS

La pantalla muestra la respuesta junto al pasaje citado.
Sirve como modelo de interfaz mientras el asistente de Laravel sigue en demostración.

https://github.com/Cinnamon/kotaemon

16 txtai GRATIS

Embeddings, búsqueda y respuesta corren en un solo proceso.
Sirve para el piloto del reglamento de ejemplo, en el mismo servidor de la tesis.

https://github.com/neuml/txtai

17 Open WebUI GRATIS

Es un chat con documentos, por espacios de trabajo.
Sirve para que consultor y especialista prueben preguntas antes de conectar la API.

https://github.com/open-webui/open-webui

18 Verba GRATIS

Subes archivos y preguntas, con Weaviate como índice, también en tu servidor.
Sirve para probar la búsqueda semántica sin un contrato.

https://github.com/weaviate/Verba

19 Semantic Kernel GRATIS

Orquesta la búsqueda y el modelo desde Python o C#.
Sirve si el servicio de inteligencia se escribe junto a otro sistema de la organización.

https://github.com/microsoft/semantic-kernel

20 Letta GRATIS

Conserva memoria entre los turnos de la charla.
Sirve para la conversación que sigue dentro del mismo expediente.

https://github.com/letta-ai/letta

21 MaxKB GRATIS

Es una base de conocimiento con panel para cargar documentos.
Sirve para que el responsable documental alimente el índice sin escribir código.

https://github.com/1Panel-dev/MaxKB

22 UltraRAG GRATIS

El pipeline se arma con piezas sueltas.
Sirve para encajar OCR, índice y modelo como sistemas externos.

https://github.com/OpenBMB/UltraRAG

23 FlashRAG GRATIS

Trae varias técnicas de RAG listas para comparar.
Sirve en la tesis para medir cuál recupera mejor el artículo citado.

https://github.com/RUC-NLPIR/FlashRAG

24 Nano-GraphRAG GRATIS

Es una versión pequeña y legible del RAG por grafo.
Sirve para un experimento sobre expedientes que se citan entre sí.

https://github.com/gusye1234/nano-graphrag

25 Embedchain GRATIS

El código queda en un archivo de solo lectura, con licencia Apache 2.0.
Sirve para consultar cómo se armaba un RAG con poca configuración.

https://github.com/mem0ai/embedchain-archive

26 Cheshire Cat GRATIS

Es un núcleo pequeño, con memoria y plugins.
Sirve para un asistente de prueba que recuerde el expediente abierto.

https://github.com/cheshire-cat-ai/core

3. Precio bajo

El código se puede instalar sin licencia. El camino cómodo cobra un plan chico, el uso del índice o una sola GPU. Dify va primero.

1 Dify PRECIO BAJO

Encabeza los de precio bajo porque el flujo se publica como API con una cuota mensual baja, o se instala en tu servidor sin licencia.
El flujo de buscar, citar y responder se arma en un panel. Esa API puede atender la búsqueda y los mensajes del asistente.

https://dify.ai/

2 Flowise PRECIO BAJO

El pipeline se dibuja en un lienzo y la nube tiene un plan de entrada.
Sirve para revisar el flujo con el especialista sin mantener un proyecto grande.

https://flowiseai.com/

3 Canopy PRECIO BAJO

El código es gratis y el índice es Pinecone, con capa gratuita y luego pago por uso.
Sirve para un piloto semántico sin administrar el clúster de vectores.

https://github.com/pinecone-io/canopy

4 RAGatouille PRECIO BAJO

El software no se cobra y pide una GPU para indexar con ColBERT.
Sirve cuando la búsqueda por palabras del reglamento se queda corta y hace falta una coincidencia más fina.

https://github.com/AnswerDotAI/RAGatouille

5 Superlinked PRECIO BAJO

Mezcla el vector con filtros de expediente, categoría y confidencialidad.
La librería no se paga; la nube se cobra por uso y, en un fondo chico, la cuenta se mantiene baja.

https://superlinked.com/

6 Pathway PRECIO BAJO

En un piloto propio se usa sin comprar licencia. Reindexa el fondo cuando entra una versión nueva.
Si LegalCloud lo vende como producto, la licencia BSL hay que leerla y puede cobrarse.

https://pathway.com/

7 Quivr PRECIO BAJO

El servicio alojado cobra un plan por la base documental.
Sirve si quieres un archivo consultable por organización sin operar el índice.

https://www.quivr.com/

4. Caros

El costo está en la licencia, en las GPU o en la cantidad de llamadas al modelo al indexar. NeMo Retriever va primero.

1 NeMo Retriever CARO

Encabeza los caros porque extrae texto, tablas y figuras del PDF y reordena los pasajes con la pila de NVIDIA.
El costo está en la licencia y en las GPU. Sirve cuando el volumen del fondo y el tiempo de respuesta piden un recuperador empresarial.

https://docs.nvidia.com/nemo/retriever/latest/

2 GraphRAG CARO

El código es libre y el gasto está en las llamadas que extraen entidades y relaciones de cada documento. Sirve para un fondo grande en el que la respuesta depende de cómo se cruzan normas y expedientes.

https://microsoft.github.io/graphrag/

3 h2oGPT CARO

La edición abierta se instala sin licencia. La vía de producción de H2O va por contrato empresarial.
Sirve para una organización que quiere el RAG en su red, con soporte y el despliegue a cargo del proveedor.

https://github.com/h2oai/h2ogpt